

Risultati esperimenti rewriting iterativo — 09/06/2026

Documento di sintesi degli esperimenti svolti finora sul problema della degradazione del contenuto in catene di rewriting iterative su MuSiQue.

Struttura del documento

- Sezione A — panoramica del run 300q (rewriter in 4-bit, QA in bf16)
- Sezione B — confronto fra il pilot 15q (bf16) e i corrispondenti qid del 300q (4-bit), per isolare l'effetto della quantizzazione
- Sintesi finale e prossimi passi

Tutti i numeri sono medie sulle catene disponibili nei rispettivi CSV.

SEZIONE A — Esperimento 300q (modello quantizzato)

Setup sperimentale

- Modello rewriter: OLMo-2-0325-32B-Instruct in 4-bit NF4 su Lisa (RTX 3090).
- Modello QA per Answer F1: OLMo-2-1124-32B-Instruct in bf16 su Homer (RTX A6000).
- OpenFactScore (AFG + AFV): in 4-bit NF4 su Lisa.
- Dataset: MuSiQue dev, sample bilanciato per hop count, target 300 q.

Stato attuale dei file di output (numero di qid coperti)

- Catene di rewriting (chains): 179 qid
- Answer F1: 110 qid
- BERTScore: 36 qid
- OpenFactScore (precision): 55 qid

Subset comune a tutte e 4 le metriche: 36 qid.


Tutte le statistiche e i grafici della Sezione A sono calcolati su questo sottoinsieme, in modo che ogni metrica venga aggregata sugli stessi documenti — confronto onesto step-per-step.

Nota metodologica

Il rewriter è quantizzato a 4-bit. Il QA è in bf16 (full-precision). Il dato Answer F1 NON è inquinato da quantizzazione del lato QA, mentre il pattern di compressione visibile su lunghezza/n_facts riflette il comportamento del rewriter quantizzato. OpenFactScore precision usa AFG/AFV in 4-bit, ma il trend tra step e instruction è preservato (il bias è uniforme).

A.1 — Lunghezza media (n_tokens) per step e instruction

Andamento del numero medio di token in E_t , calcolato sui 36 qid in comune. Lo step 0 corrisponde al testo di partenza (E_0). Se l'instruction agisce come dovrebbe ci si aspetta: shorten ↓, elaborate ↑, paraphrase e formality stabili.




A.1 — Tabella: n_tokens medi per instruction × step

Valori medi sui 36 qid in comune. Si noti che anche elaborate produce meno token rispetto a E_0 → segnale che il rewriter quantizzato tende a comprimere indipendentemente dall'instruction.

instruction_type	0	1	2	3
elaborate	2378.722	757.685	683.917	667.685
formality	2378.722	980.259	785.657	686.722
paraphrase	2378.722	665.519	501.907	422.713
shorten	2378.722	536.852	400.083	353.426

A.2 — Answer F1 medio per step e instruction

F1 dell'output del modello QA su 36 qid in comune. Lo step 0 misura la baseline F1 sul testo originale. Una caduta forte indica che l'informazione necessaria a rispondere si è persa nel rewriting.




A.2 — Tabella: Answer F1 medio per instruction × step

Tutti i tipi di instruction degradano F1 in modo simile → la perdita di informazione non dipende dal tipo di intervento ma dal fatto stesso di iterare il rewriting con un modello quantizzato.

instruction_type	0	1	2	3
elaborate	0.423	0.299	0.252	0.256
formality	0.423	0.322	0.26	0.247
paraphrase	0.423	0.261	0.226	0.222
shorten	0.423	0.26	0.199	0.205

A.3 — BERTScore F1 baseline (similarità di E_t con E_0)

Misura quanto E_t è ancora semanticamente simile a E_0 . Calcolato con roberta-large. Valori vicini a 1 = E_t è quasi identico a E_0 . Una discesa rapida indica drift dal contenuto originale.




A.3 — Tabella: BERTScore F1 vs E_0

elaborate è l'instruction che si allontana di più da E_0; le altre tre restano in un range simile.

instruction_type	1	2	3
elaborate	0.85	0.84	0.835
formality	0.886	0.877	0.871
paraphrase	0.856	0.845	0.841
shorten	0.849	0.84	0.837


A.4 — BERTScore F1 consecutive (similarità con lo step precedente)

Misura quanto cambia il testo da uno step al successivo. Valori che salgono verso 1 indicano che il rewriting si stabilizza: dopo le prime iterazioni il modello cambia poco.



A.5 — OpenFactScore precision (init_score) per step

Frazione di fatti estratti da E_t che sono supportati da E_0 . Misura quanto il rewriter è fedele al contenuto originale: 1.0 = nessun fatto inventato. Calcolato sui 36 qid in comune.



A.5 — Tabella: OFS precision per instruction × step

elaborate è l'unica con caduta significativa di precision ($\approx$ -5pp dopo 3 step) → conferma che l'instruction 'elabora' spinge il modello a introdurre fatti non supportati da E_0.

instruction_type	1	2	3
elaborate	0.918	0.883	0.869
formality	0.918	0.909	0.89
paraphrase	0.922	0.91	0.898
shorten	0.906	0.901	0.89

A.6 — Tabella: numero medio di fatti estratti da E_t

Anche elaborate produce sempre meno fatti a ogni step (es. 80→70 al posto di crescere). Sintomo che il rewriter quantizzato non segue l'instruction 'aggiungi dettagli' e finisce per comprimere.

instruction_type	1	2	3
elaborate	81.713	73.426	70.611
formality	106.676	82.537	71.963
paraphrase	75.63	54.63	45.759
shorten	66.694	50.722	44.833

SEZIONE B — Confronto full-precision (15q) vs 4-bit (300q)

Obiettivo

Isolare l'effetto della quantizzazione 4-bit del rewriter, confrontando il pilot 15q (rewriter in bf16 su Homer) con il sottoinsieme degli stessi qid presenti nel run 300q (rewriter in 4-bit su Lisa).

Qid in comune fra i due esperimenti: 10 su 15.

- 2hop_14092_8311, 2hop_5658_25002, 2hop_61143_165532, 2hop_612719_6455, 2hop_635544_110949, 3hop1_19768_19788_10117, 3hop1_305566_568433_47686, 3hop1_593288_720914_41132, 3hop1_840353_503371_21711, 3hop2_28727_92991_76291

Nota metodologica


Stesso modello (OLMo 32B Instruct), stesso prompt template, stessi qid, stesso pipeline. Sola variabile: la quantizzazione 4-bit del rewriter. L'Answer F1 sui 300q è in bf16 (Homer) — quindi la differenza F1 osservata rispetto al 15q è attribuibile ai DIVERSI testi prodotti dal rewriter, non al QA model.

Ogni grafico/tabella della Sezione B è ristretto a questi qid in comune.


B.1 — Lunghezza (n_tokens) per step e instruction

Confronto a parità di qid (10).
Blu = bf16 (15q),
rosso = 4-bit (300q).
Se il modello quantizzato comprime di più,
le barre rosse saranno più basse.


shorten




paraphrase



formality



elaborate







B.1 — Δ n_tokens (300q – 15q) per instruction × step

Delta in token tra 4-bit e bf16 sui 10 qid in comune. Numeri negativi indicano che il modello 4-bit produce meno token. elaborate dovrebbe avere delta vicino a 0 o positivo se la quantizzazione non interferisse con l'instruction following.

instruction_type	0	1	2	3
elaborate	-52	-922	-1026	-1083
formality	-52	-445	-548	-607
paraphrase	-52	-398	-448	-461
shorten	-52	-142	-146	-154

B.2 — Answer F1 per step e instruction

Confronto a parità di qid (10).
Se le barre rosse (4-bit) sono molto più basse,
la quantizzazione del rewriter sta facendo
sparire la risposta dal testo.







B.2 — Δ Answer F1 (300q – 15q) per instruction × step

Delta F1 tra 4-bit e bf16. Valori negativi grandi confermano che il rewriter quantizzato distrugge l'informazione necessaria al QA.

instruction_type	0	1	2	3
elaborate	0.0	-0.009	-0.144	-0.166
formality	0.0	-0.001	-0.022	-0.007
paraphrase	0.0	-0.026	-0.101	-0.122
shorten	0.0	-0.066	-0.021	-0.066





B.3 — BERTScore F1 vs E_0 (drift cumulativo)

Quanto E_t resta simile a E_0 (10 qid in comune).



B.4 — OpenFactScore precision (init_score)

Fedeltà al contenuto di E_0 (10 qid in comune). OFS è meno sensibile alla quantizzazione (AFG/AFV dovrebbero comportarsi in modo simile) — eventuali differenze importanti sono indicative.



Sintesi e prossimi passi

Sintesi dei risultati

1. Pattern di compressione

Anche il rewriter in bf16 (15q) tende a comprimere il testo invece di rispettare rigorosamente le instruction (specialmente con input lunghi 2300+ token come in MuSiQue). Tuttavia il modello 4-bit (300q) amplifica nettamente questo comportamento: a step 3 produce in media molti meno token di quanto faccia il modello bf16 a parità di qid e instruction.

- elaborate · step 3 · bf16: 1621 token vs 4-bit: 538 token
- shorten · step 3 · bf16: 439 token vs 4-bit: 285 token

2. Answer F1 (perdita di informazione)

Sui 15q full-precision, F1 a step 3 resta molto vicino allo step 0 — il rewriter preserva l'informazione necessaria a rispondere. Sui 300q in 4-bit, F1 a step 3 scende quasi alla metà della baseline.

- elaborate · bf16: $F1(E_0)=0.294 \rightarrow F1(E_3)=0.347$
- elaborate · 4-bit: $F1(E_0)=0.294 \rightarrow F1(E_3)=0.181$

3. Implicazioni

I dati suggeriscono che la quantizzazione 4-bit non degrada solo la qualità del rewriting in modo uniforme, ma rompe specificamente la capacità del modello di seguire instruction che richiedono espansione (elaborate). L'effetto a cascata è che, dopo 3 iterazioni, le risposte alle domande non sono più estraibili dal testo riscritto.

4. Limiti dei numeri attuali

- Il 300q non copre ancora tutti i 300 qid: 110 hanno F1, 36 hanno BERTScore, 55 hanno OFS. Tutti i numeri della Sezione A sono calcolati sull'intersezione.
- Il subset comune fra 15q e 300q è di 10 qid; statisticamente è un campione piccolo. Le differenze qualitative sono però marcate e coerenti con quanto osservato sui pieni 300q.
- OpenFactScore in 4-bit potrebbe avere un piccolo bias rispetto a OFS in bf16 (stesso AFG/AFV usato in entrambe le run). Il trend tra step e instruction è comunque preservato.

5. Prossimi passi suggeriti

- Completare il run 300q (resume) per portare F1/BERT/OFS allo stesso copertura.
- Replicare il pilot 15q anche in 4-bit per un confronto più diretto e con più qid (questo isolerebbe quantizzazione vs sample).
- Considerare di passare a NewsQA o FictionalQA per l'esperimento finale: input più corti (~370-700 token) limitano il problema della 'compressione implicita' indotta dal task lungo.